Generative Models Continued…

Naive Bayes classifiers

- The model is called **"naive"** since we do not expect the features to be independent.

$$p(\mathbf{x}, \mid y = c\boldsymbol{\theta}) = \prod_{d=1}^{D} p(x_d \mid y = c, \boldsymbol{\theta}_{dc})$$

$$p(y, = c \mid \mathbf{x}, \boldsymbol{\theta}) = \frac{p(y = c \mid \boldsymbol{\pi}) \prod_{d=1}^{D} p(x_d \mid y = c, \boldsymbol{\theta}_{dc})}{\sum_{c'} p(y = c' \mid \boldsymbol{\pi}) \prod_{d=1}^{D} p(x_d \mid y = c', \boldsymbol{\theta}_{dc'})}$$

Naive bayes

Binary classification

$y \in \{0,1\}$ $\quad X = \{X_1, X_2, \dots, X_n\}$ $\quad X_i \in \{0,1\}$, $i = 1 \dots n$

$\arg\max p(Y = y \mid X = x)$ ⟶ 2^n parameter is needed

$P(y=1 \mid X = x)$

We suppose: Naive Bayes Assumption

$$p(X = x|Y = y) = \prod_{i=1}^{n} p(X_i = x_i|Y = y)$$

$P(y)$

$2n+1$ ← تعداد پارامترهای مورد نیاز ⟸ به شرط استقلال کلاس y از ویژگی‌های $X_1, X_2, \dots, X_n$

ML: $\arg\max P(Y = y)P(X = x)|Y = y)$

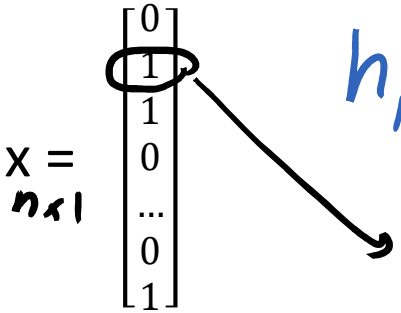
$P(X)$

$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$

Text classification with naive bayes

EX: Email classification $\begin{cases} \text{spam} & 1 \\ \text{Non} - \text{spam} & 0 \end{cases}$

دیکشنری شامل n کلمه



$X_i = 1$ اگر کلمه i ام در ایمیل وجود باشد

$$h_{Bayes}(x) = \underset{y \in \{0,1\}}{\operatorname{argmax}} P(Y=y) \frac{P(X=x \mid Y=y)}{\prod_{i=1}^{n} P(X_i = x_i \mid Y=y)}$$

$(X^{(i)})_k = 1$ اگر کلمه k ام در نمونه آموزشی (ایمیل) i ام وجود بود

$n = 5000$

$$P(x_1, x_2, \ldots, x_{50000} | y) = \prod_{i=1}^{50000} P(x_i | y)$$

$$P(X_i | y = 1) = \phi_i | y = 1 \quad n$$

$$P(X_i | y = 0) = \phi_i | y = 0 \quad n \quad \Rightarrow \quad 2n+1$$

$$P(y = 1) = \phi_y \quad 1$$

تعداد ایمیل‌ها در داده‌های آموزشی

$$L(\phi_y, \phi_i | y = 0, \phi_i | y = 1) = \prod_{i=1}^{m} p(x^{(i)}, y^{(i)}) \xrightarrow{\text{ML}} \begin{cases} \phi_i | y = 1 \\ \phi_i | y = 0 \\ \phi_y \end{cases}$$

Find optimum value

ML result

$$\phi_{j|y}=1=\frac{\sum_{i=1}^{m}1\{X_j^{(i)}=1 \wedge y^{(i)}=1\}}{\sum_{i=1}^{m}1\{y^{(i)}=1\}}$$

$$\phi_{j|y}=0=\frac{\sum_{i=1}^{m}1\{X_j^{(i)}=1 \wedge y^{(i)}=0\}}{\sum_{i=1}^{m}1\{y^{(i)}=0\}}$$

$$\phi_y=\sum_{i=1}^{m}\frac{1\{y^{(i)}=1\}}{m}$$

New Email: X_{test} → Predict → $\hat{y}=\max(\,(P(y=1|X_{test}),(P(y=0|X_{test}))\,)$

اگر x_j گسسته و به جای $\{1, 2, \dots, k_j\}$ می‌تواند مقادیر $\{1, 2, \dots, k_j\}$ را اختیار کند

= به جای توزیع نرمال ← توزیع categorical

$$\begin{cases} P(x_j = 1 \mid y = 1) = \phi_{j|y=1} \\ P(x_j = 2 \mid y = 1) \\ P(x_j = k_j \mid y = 1) \end{cases} \qquad \phi_{j|y=0}$$

$$\phi_{jk_j|y=1} \qquad \phi_{jk_j|y=0}$$

در برخی مسائل ویژگی‌ها پیوسته هستند می‌توان به گسسته تبدیل کرد و از Naive Bayes استفاده کرد.

برای مثال قیمت خانه‌ها:

50 تا 60 متر $\rightarrow$ 0

60 تا 70 $\rightarrow$ 1

70 تا 80 $\rightarrow$ 2

...

Kernel density estimation

Laplace smoothing

$$\phi_{j|y=1} = \frac{1 + \sum_{i=1}^{n} 1\left\{x_j^{(i)} = 1 \wedge y^{(i)} = 1\right\}}{2 + \sum_{i=1}^{n} 1\{y^{(i)} = 1\}}$$

$$\phi_{j|y=0} = \frac{1 + \sum_{i=1}^{n} 1\left\{x_j^{(i)} = 1 \wedge y^{(i)} = 0\right\}}{2 + \sum_{i=1}^{n} 1\{y^{(i)} = 0\}}$$

اگر ها کلاسه باشند
۱۱
۱ در صورت و
۲ در مخرج اضافه
می‌شود

non-spam ها در اسپم spam ها در

مشکلی که وجود دارد ← اگر یکی از کلمات دیکشنری
در داده آموزشی وجود نداشته باشد، $\phi_{j|y=0} = 0$
$\phi_{j|y=1} = 0$

ϕ_y

GAN و VAE مدل‌های مولد تلقی می‌شوند

Bayesian Models

مدل های بیزین

اطلاعات قبلی راجع به پارامتر مجهول θ با توزیع احتمال پیشین $P(\theta)$

prior distribution

Posterior distribution $P(\theta \mid X, Y)$

uncertainty عدم قطعیت

به مسئله استنتاج می‌شود ← یعنی با داده‌های آموزشی $(X^{(i)}, Y^{(i)})$

حالی یک نقطه‌ای یک توزیع روی θ مشخص می‌کند

$$p(\theta \mid x^{(i)}, y^{(i)}) = \frac{\prod_{i=1}^{m} p(y^{(i)} \mid x^{(i)}, \theta)\, p(\theta)}{\int_{\theta} \prod_{i=1}^{m} p(y^{(i)} \mid x^{(i)}, \theta)\, p(\theta)\, d\theta}$$

↑ θ ثابت ←

معمولاً توزیع پسین پارامترها به صورت تقریبی بدست می آید.

۱- روش‌های عددی مانند MCMC - Sampling

۲- روش‌های کلی Variational inference

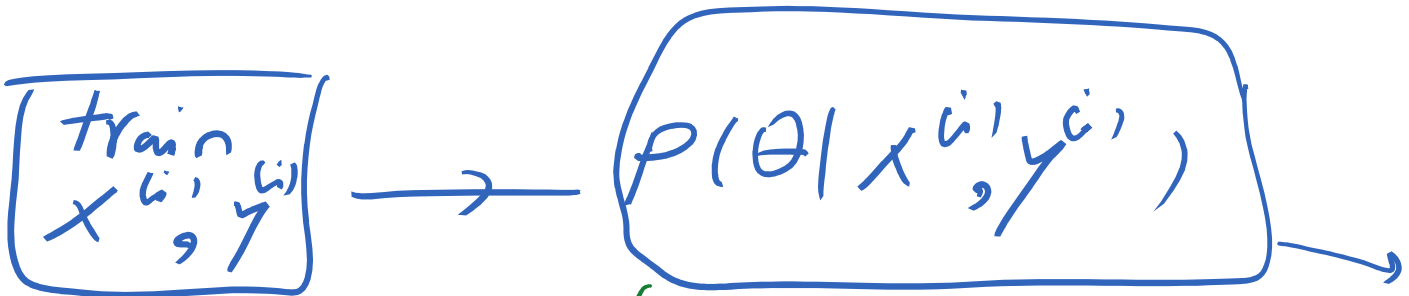
معمولاً توزیع prior $P(\theta)$ را به واحد یا یکی (یا آنتروپی بالا) تعیین می‌شود

بعد از دیدن مشاهدات $(x^{(i)}, y^{(i)})$ توزیع پسین Θ (با آنتروپی کاهش یافته) بدست می‌آید ← Θ بهینه

$\langle -\log P(\theta) \rangle_{P(\theta)}$

$E(-\log P(\theta))$

برای ورودی x_{test} می‌توان چه مقادیری از θ را در تخمین خروجی y_{test} به کار برد.



$p(\theta)$

$p(y^{(i)} | x, \theta)$

MAP تخمین

$\theta_{opt} = \underset{\theta}{Argmax} P(\theta | x, y)$

$x_{test} \rightarrow y_{test} = \underset{y}{\arg\max}\, p(y | x_{test}, x^{(i)}, y^{(i)})$

$\int_{\theta} p(y | x_{test}, \theta)\, p(\theta | x^{(i)}, y^{(i)})\, d\theta$

$x_{test} \rightarrow y_{test} = \underset{y}{\arg\max}\, P(y | x_{test}, \theta_{opt})$

مثال- مدل رگرسیون خطی

$p(Y|X,\theta)$ گوسی

فرض: θ هم متغیر تصادفی با توزیع گوسی در نظر گرفته شود.

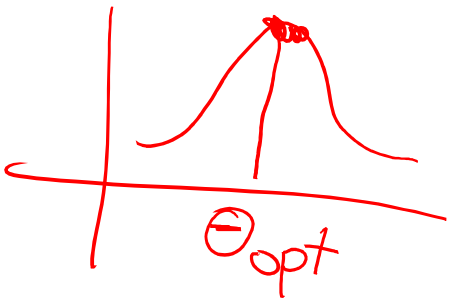
$p(\theta) = N(\underline{\mu}_0, \Lambda_0)$ $\quad \Lambda_0 = diag(\lambda_0)$ $\begin{bmatrix} \lambda_0 & & 0 \\ & \ddots & \\ 0 & & \lambda_0 \end{bmatrix}$

توزیع پسین $\hat{\theta}$: $p(\theta|X,Y) \propto p(Y|X,\theta)p(\theta)$

$$\propto \exp\left(-\frac{1}{2}(\underline{y} - \underline{\underline{X}}\,\underline{\theta})^T(\underline{y} - \underline{\underline{X}}\,\underline{\theta})\right)_{\times}$$

$$\exp\left(-\frac{1}{2}(\underline{\theta} - \underline{\mu}_0)^T \Lambda_0^{-1}(\underline{\theta} - \underline{\mu}_0)\right) \propto$$

$$\exp\left(-\frac{1}{2}(\underline{\theta} - \underline{\mu}_m)^T \Lambda_m^{-1}(\underline{\theta} - \underline{\mu}_m)\right)$$



$$\underline{\underline{X}}_{m\times n} = \begin{bmatrix} \underline{x}^{(1)T} \\ \vdots \\ \underline{x}^{(m)T} \end{bmatrix} \qquad \underline{y} = \begin{bmatrix} y^{(1)} \\ \vdots \\ y^{(m)} \end{bmatrix}$$

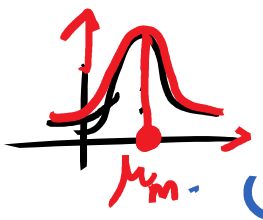
$$\underline{\Lambda}_m = (\underline{\underline{X}}^T \underline{\underline{X}} + \underline{\Lambda}_0^{-1})^{-1} \quad , \quad \underline{\mu}_m = \underline{\Lambda}_m (\underline{\underline{X}}^T \underline{y} + \underline{\Lambda}_0^{-1} \underline{\mu}_0)$$

چگونه η را بدست آورده تا آنچه از حل Normal برای مسئله رگرسیون G_q.

حفظی بدست آمد چه تساوی دارد؟

$$\theta = \ldots$$

$$(\underline{\mu}_0 = \underline{0} \ , \ \underline{\Lambda}_0 = \frac{1}{\alpha} \cdot \text{راهنمای}) \qquad \begin{bmatrix} \frac{1}{\alpha} & 0 \\ 0 & \frac{1}{\alpha} \end{bmatrix}$$



μ_m: میانگین توزیع پسین برای θ است

$$\theta_{opt} = \mu_m$$

MAP Estimation

MAP Estimation:

معمولاً تخمین توزیع پسین کار ساده‌ای نیست. پس باز هم به دنبال تخمین نقطه‌ای از θ هستیم:

$$\theta_{MAP} = \arg\max_{\theta} p(\theta \mid \underbrace{X, Y}_{\text{مشاهدات}})$$

$$= \arg\max_{\theta} \boxed{p(Y \mid X, \theta) \times p(\theta)}$$

$$\log \quad \arg\max_{\theta} \log p(Y \mid X, \theta) + \boxed{\log p(\theta)}$$

می‌توانند بطوان همان جریمه پایداری سازی تلقی شوند

Regularization

$p(\theta) \sim N(0, \frac{1}{\lambda}) \Rightarrow \log p(\theta) \rightarrow \lambda \theta^T \theta$

معادل با پایدارساز L_2-norm

کمتین MAP ست ~ ML (که θ توزیع پیش‌دانست) می‌تواند کمتین واریانس کمتر بدهد. (ولی می‌تواند باعث افزایش بایاس شود)

معادل با استفاده از پایدارسازی که پیش‌لازش را کاهش می‌دهد

prior: GMM → توزیع پیش

Smoothness sparsity

مفهوم توزیع پیشین مزدوج:
Conjugate prior

$P(\theta)$ نوسی — $P(Y \mid X, \theta)$ نوسی $\Rightarrow$ $P(\theta \mid X, Y)$ نوسی

توزیع CP توزیعی است که نوسی است.

$P(\theta)$ ماما — $P(Y \mid X, \theta)$ پواسون $\Rightarrow$ $P(\theta \mid X, Y)$ ماما

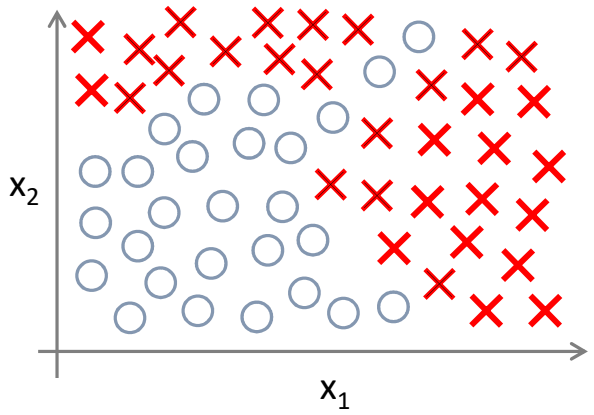
ماما توزیع پیشین مزدوج برای پواسون است.

فقط مامایی است با پارامترهای توزیع پسین را بدست آورد.

Neural networks

Motivation

Non-linear Classification



$x_1 =$ size
$x_2 =$ # bedrooms
$x_3 =$ # floors
$x_4 =$ age
$\dots$
x_{100}

$$g(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1 x_2 + \theta_4 x_1^2 x_2 + \theta_5 x_1^3 x_2 + \theta_6 x_1 x_2^2 + \dots)$$

$$O(n^2) = 5000$$

Classification problem

You see this:



50 x 50 = 2500
pixel

2500 x 3 = 7500
RGB

$n_i \times n_j$

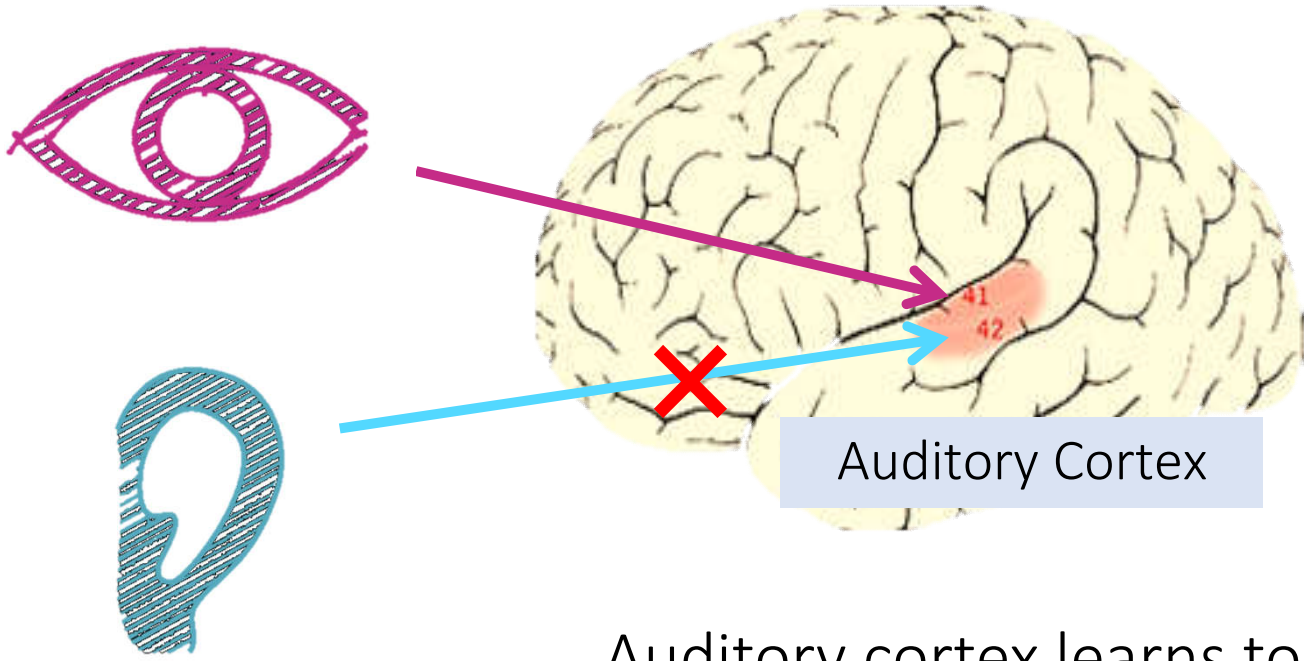
↓

~ 2,43M

What is our problem?

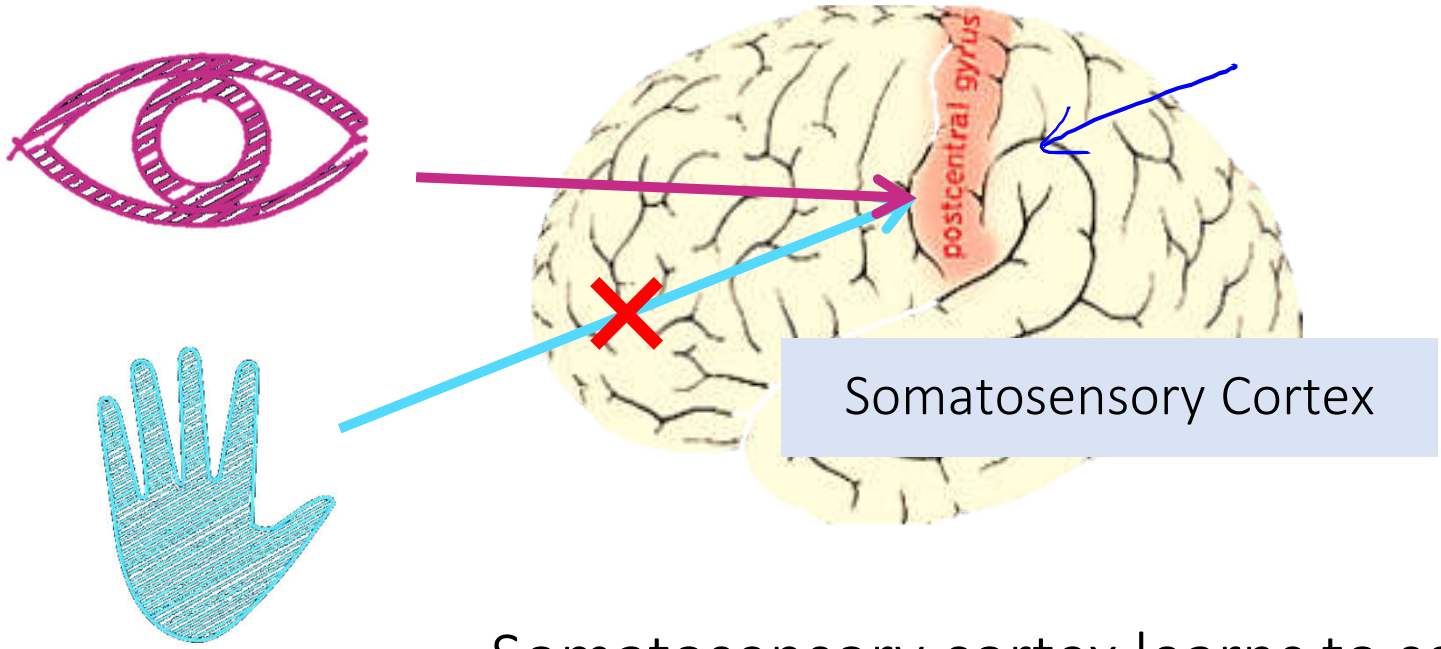
1. Nonlinear
2. Complex models

The “one learning algorithm” hypothesis



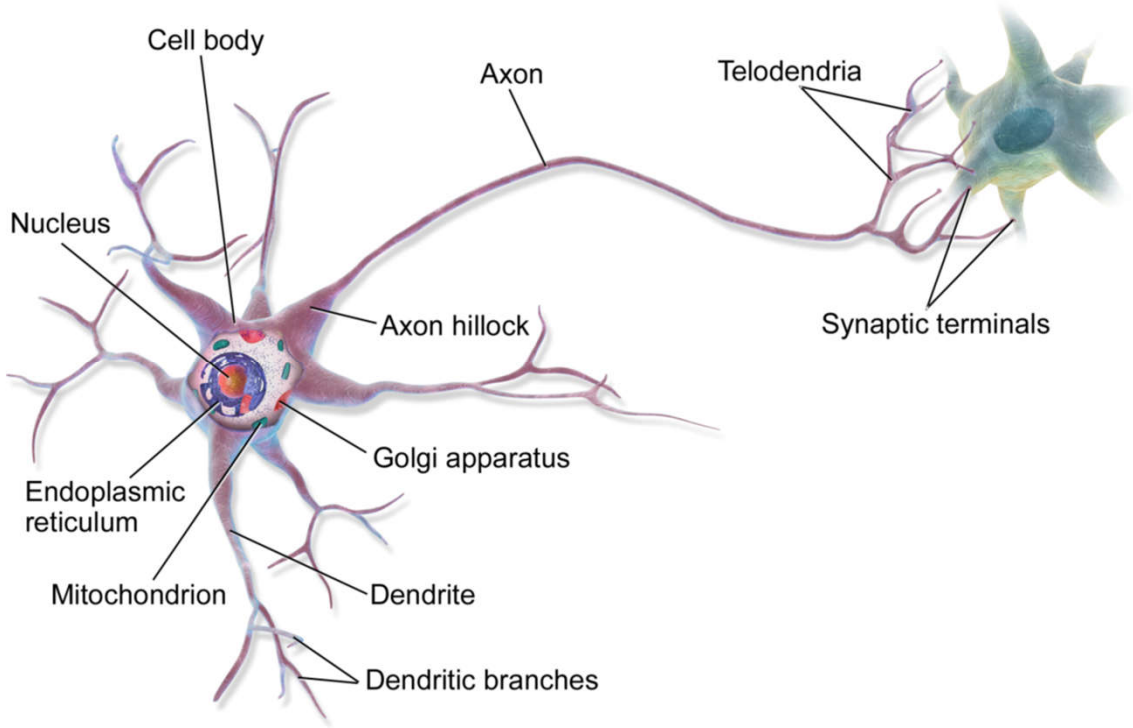
Auditory cortex learns to see

The “one learning algorithm” hypothesis



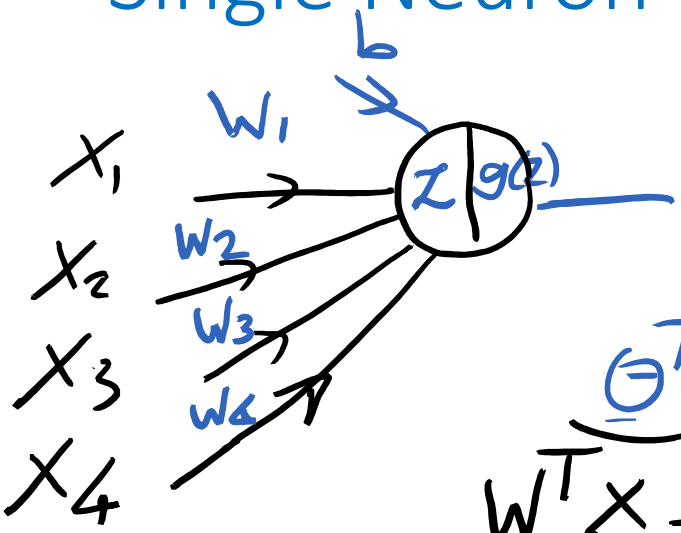
Somatosensory cortex learns to see

Neuron


Cell body
Axon
Telodendria
Nucleus
Axon hillock
Synaptic terminals
Golgi apparatus
Endoplasmic reticulum
Mitochondrion
Dendrite
Dendritic branches

Single Neuron neural network

بیس سی صمت :



$h_\theta(x) = \max(\theta^T X, 0)$

$\theta^T X = \theta_0 X_0 + \theta_1 X_1 + \theta_2 X_2 + \theta_3 X_3 + \theta_4 X_4$

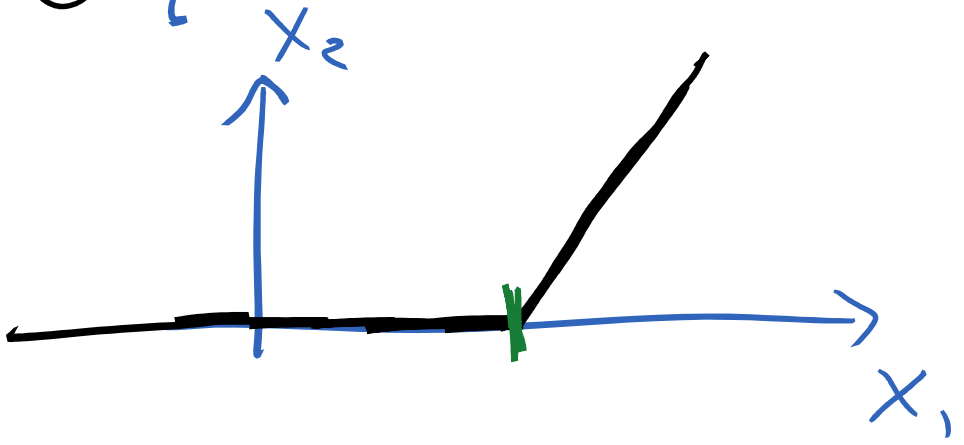
$W^T X + b$

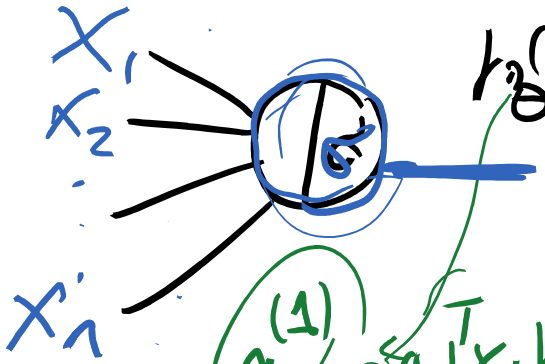
وزن‌ها — بایاس

تابع خطی

$g(z) = \max(0, z)$

ReLU
(Rectified Linear Unit)





$h_\theta(x) = \sigma(w^T x + b)$

طبقه‌بندی باینری

log. با مدل

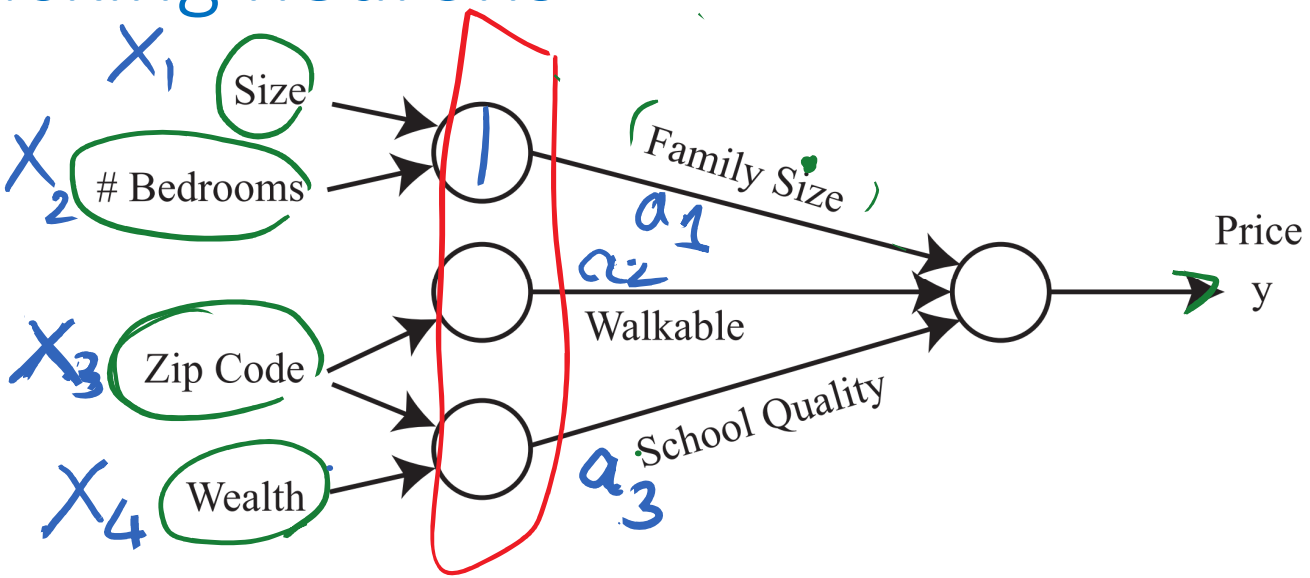
Reg.

$a^{(1)} = g(w_1^T x + b_1)$

$a^{(2)} = g(w_2 a^{(1)} + b_2)$

$$g(z) = \frac{1}{e^{-z} + 1}$$

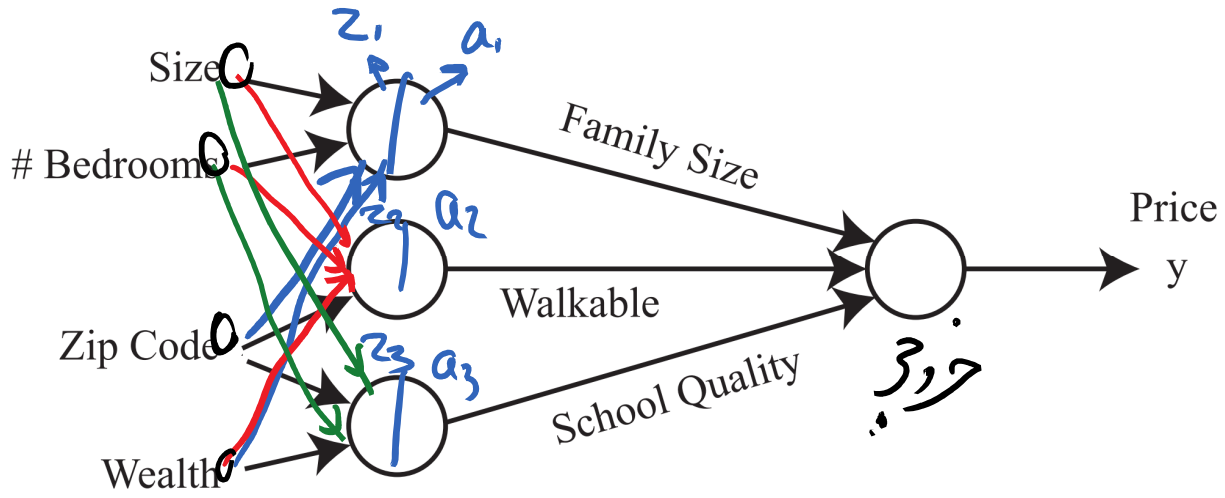
Stacking neurons



$$a_1 = \text{ReLU}(\theta_1 x_1 + \theta_2 x_2 + \theta_3)$$
$$a_2 = \text{ReLU}(\theta_4 x_3 + \theta_5)$$
$$a_3 = \text{ReLU}(\theta_6 x_3 + \theta_7 x_4 + \theta_8)$$

$$\bar{h}_\theta(x) = \theta_9 a_1 + \theta_{10} a_2 + \theta_{11} a_3 + \theta_{12}$$

Two-layer fully connected neural network



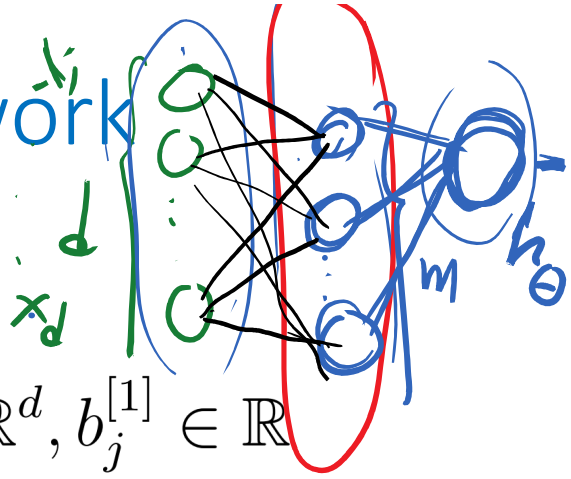
$$a_1 = \text{ReLU}(w_1^\top x + b_1), \text{ where } w_1 \in \mathbb{R}^4 \text{ and } b_1 \in \mathbb{R}$$

$$a_2 = \text{ReLU}(w_2^\top x + b_2), \text{ where } w_2 \in \mathbb{R}^4 \text{ and } b_2 \in \mathbb{R}$$

$$a_3 = \text{ReLU}(w_3^\top x + b_3), \text{ where } w_3 \in \mathbb{R}^4 \text{ and } b_3 \in \mathbb{R}$$

$$h_\theta(x) = \theta_1 a_1 + \theta_2 a_2 + \theta_3 a_3 + \theta_4$$

Two-layer fully connected neural network



$$\forall j \in [1, ..., m], \quad z_j = w_j^{[1]\top} x + b_j^{[1]} \text{ where } w_j^{[1]} \in \mathbb{R}^d, b_j^{[1]} \in \mathbb{R}$$

$$a_j = \text{ReLU}(z_j),$$

$$a = [a_1, \ldots, a_m]^\top \in \mathbb{R}^m$$

$$\bar{h}_\theta(x) = w^{[2]\top} a + b^{[2]} \text{ where } w^{[2]} \in \mathbb{R}^m, b^{[2]} \in \mathbb{R},$$

$$\underline{W}^{[1]} = \begin{bmatrix} w_1^{[1]\top} \\ w_2^{[1]\top} \\ \vdots \\ w_m^{[1]\top} \end{bmatrix}_{m \times d} \qquad z_{m\times 1} = \begin{bmatrix} z_1 \\ \vdots \\ z_m \end{bmatrix}$$

$$\underset{m\times 1}{z} = \underset{m\times d}{W^{[1]}} \underset{d\times 1}{X} + \underset{m\times 1}{b^{[1]}} \qquad \underset{m\times 1}{a} = \text{ReLU}(z)$$

ماتریسی-برداری کردن ← GPU

برای محاسبات سریع‌تر

$$MM \rightarrow g \rightarrow MM \rightarrow g \cdots \rightarrow g \rightarrow h_\theta(x)$$

$$a^{(1)} = g(W^{[1]T} x + b) \qquad a^{(2)} = g(W^{[2]T} a + b)$$

$\theta^T x$

تابع فعال‌ساز (غیرخطی)

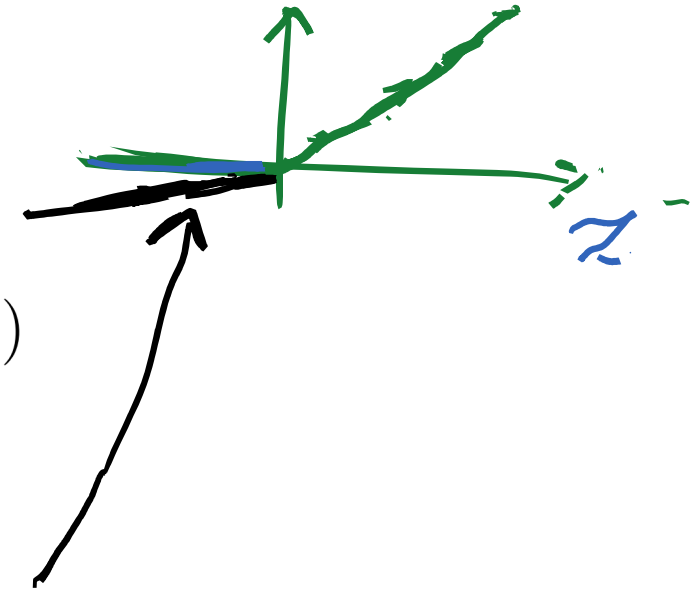
$$h_\theta(x) = f_l(f_{l-1}(f_{l-2}(\cdots(f_1(x)))$$

Multilayer fully connected neural network

$$
\begin{aligned}
a^{[1]} &= \mathrm{ReLU}(W^{[1]}x + b^{[1]}) \\
a^{[2]} &= \mathrm{ReLU}(W^{[2]}a^{[1]} + b^{[2]}) \\
&\dots \\
a^{[r-1]} &= \mathrm{ReLU}(W^{[r-1]}a^{[r-2]} + b^{[r-1]}) \\
\bar{h}_\theta(x) &= W^{[r]}a^{[r-1]} + b^{[r]}
\end{aligned}
$$

نقشه‌ی ویژگی توسط شبکه یاد گرفته شده ∅ (X)

Activation Functions



$$\sigma(z) = \frac{1}{1+e^{-z}} \qquad \text{(sigmoid)}$$

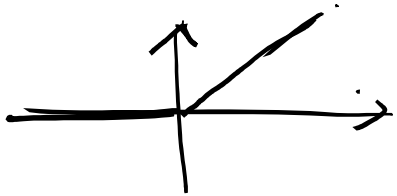
$$\sigma(z) = \frac{e^{z}-e^{-z}}{e^{z}+e^{-z}} \qquad \text{(tanh)}$$

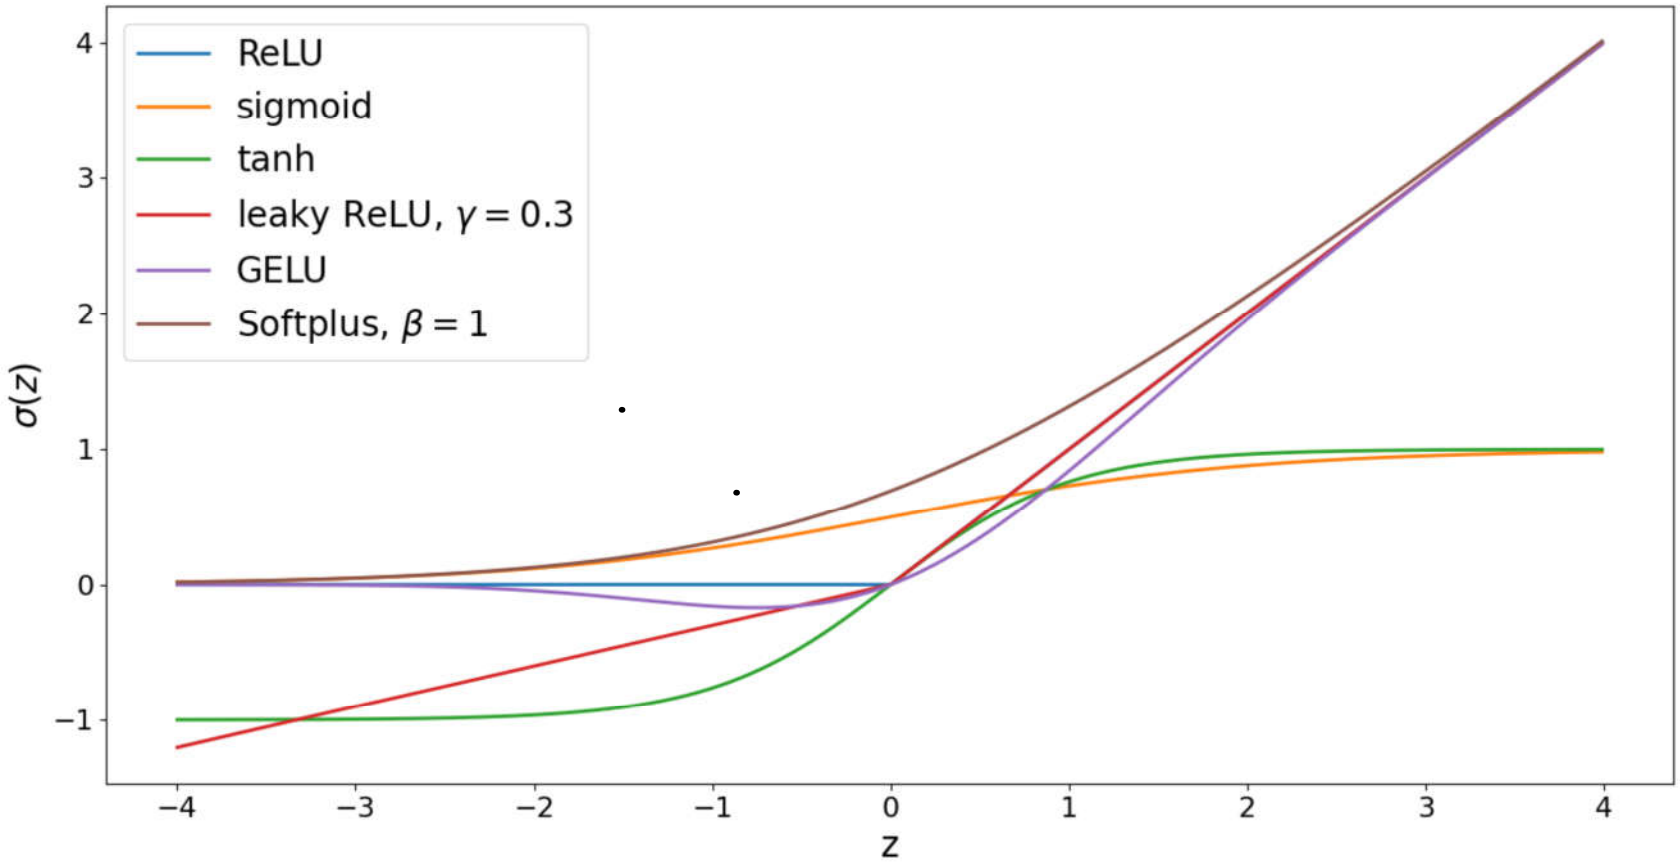
$$\sigma(z) = \max\{z, \gamma z\}, \gamma \in (0,1) \qquad \text{(leaky ReLU)}$$

$$\sigma(z) = \frac{z}{2}\left[1+\text{erf}(\frac{z}{\sqrt{2}})\right] \qquad \text{(GELU)}$$

$$\sigma(z) = \frac{1}{\beta}\log(1+\exp(\beta z)), \beta > 0 \qquad \text{(Softplus)}$$

Activation Functions





Why don't we use identity function?

$$
\begin{aligned}
\bar{h}_\theta(x) &= W^{[2]} a^{[1]} \\
&= W^{[2]} \sigma(z^{[1]}) \\
&= W^{[2]} z^{[1]} \\
&= W^{[2]} W^{[1]} x \\
&= \tilde{W} x
\end{aligned}
$$

$f_L(f_{L-1}(\cdots f_1(x)))$

$\circ_{i=1}^{L} f_i$

Connection to the kernel method…

$$\bar{h}_\theta(x) = W^{[r]}\phi_\beta(x) + b^{[r]}$$

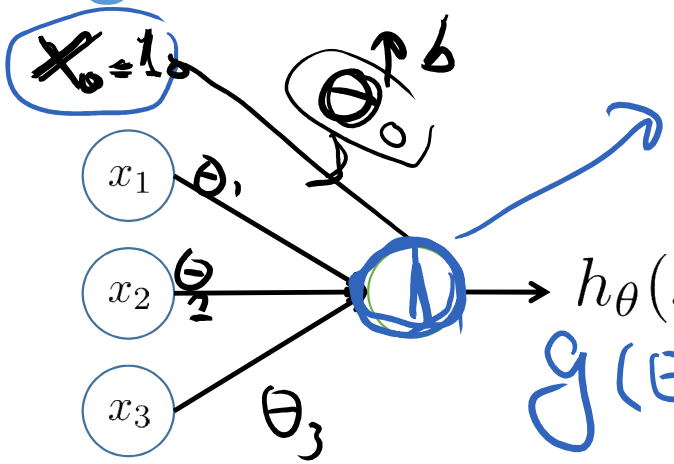
نقشه ویژگی

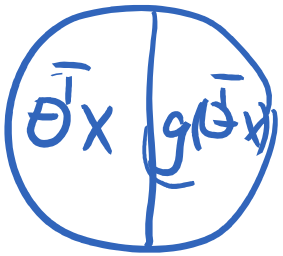
Neuron model: Logistic unit

$z = \theta^T x$

$a = \sigma(\theta^T x)$

$a = \frac{1}{1 + e^{-\theta^T x}}$





$b = \theta_0$

w, b

θ_i $\quad i = 0 \ldots n$

$x_0 = 1$

$$x = \begin{bmatrix} x_0 \\ x_1 \\ x_2 \\ x_3 \end{bmatrix} \qquad \theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \theta_3 \end{bmatrix}$$

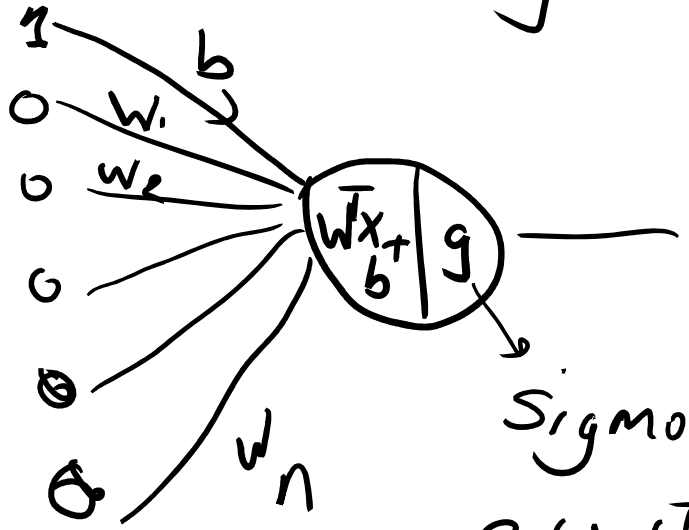
$g(\theta^T x)$

$\theta^T x = \theta_0 x_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_3$

$a = g(\theta^T x)$

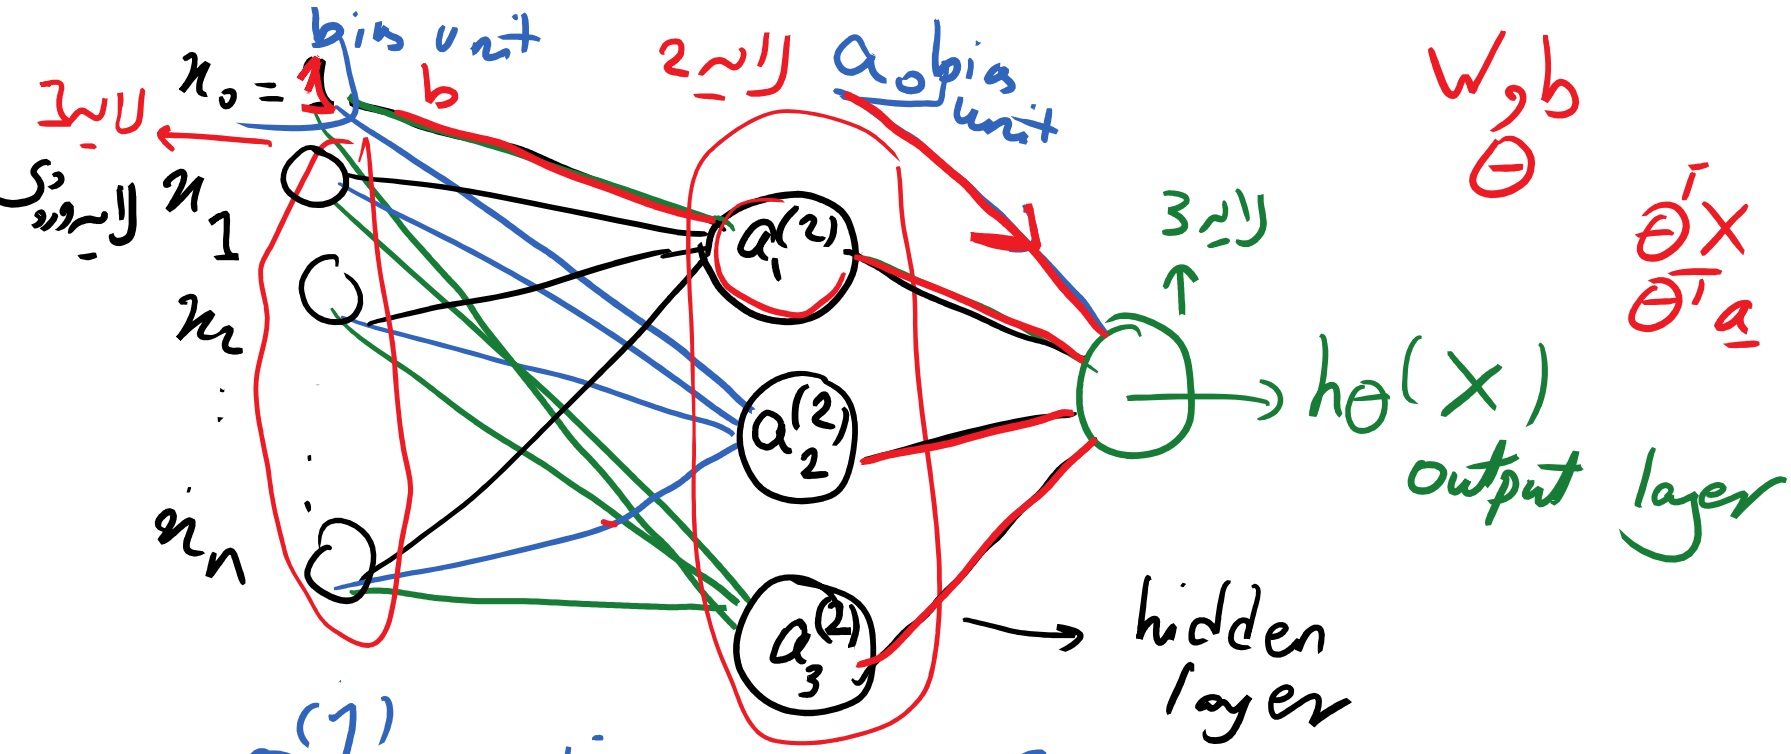
Sigmoid (logistic) activation function.

perceptron learning model:



$g(\bar{w}^T x + b)$

$$\begin{cases} \bar{w}^T x + b > 0 \rightarrow y = 1 \\ \bar{w}^T x + b < 0 \rightarrow y = 0 \end{cases}$$

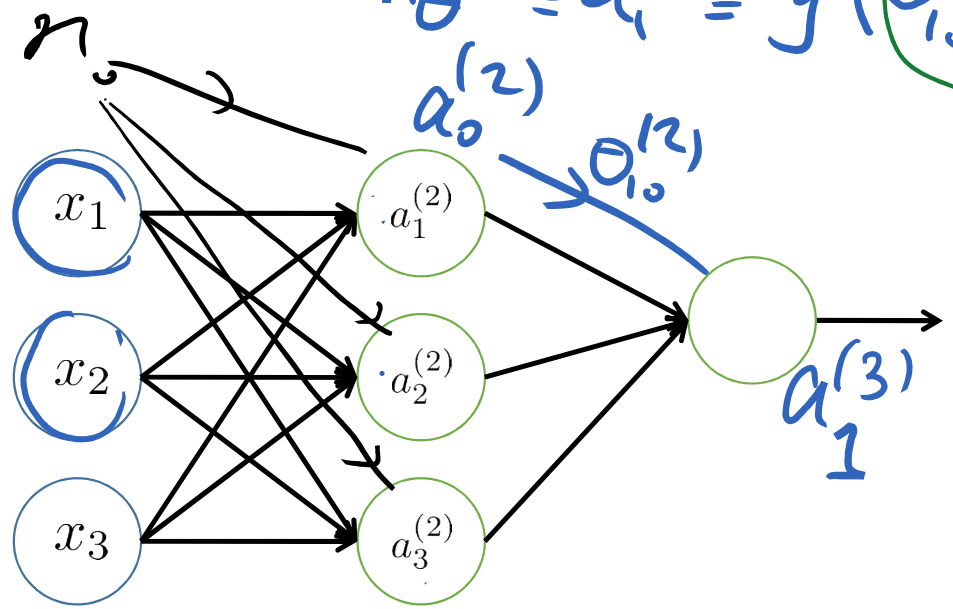


$\theta^{(1)}$: ماتریس وزن‌های لایه اول

$a_i^{(j)}$ = activation of unit i in layer j

$$a_1^{(2)} = g\left(\theta_{10}^{(1)} x_0 + \theta_{11}^{(1)} x_1 + \theta_{12}^{(1)} x_2 + \dots \theta_{1n}^{(1)} x_n\right)$$

Neural Network



$a_i^{(l)}$ ناسین خروجی لایه i

$a^{(l)} = g(z^{(l)})$

$\Theta_{ij}^{(l)}$ شماره نورون خروجی — شماره بوز ورودی

$a_0^{(2)}$ $\Theta_{10}^{(2)}$

$h_\Theta(x) = a_1^{(3)} = g(\Theta_{10}^{(2)(2)} a_0 + \Theta_{11}^{(2)(2)} a_1 + \Theta_{12}^{(2)(2)} a_2 + \Theta_{13}^{(2)(2)} a_3)$

$z_1^{(3)}$

$a_1^{(3)}$

$a_2^{(2)} = g(\Theta_{20}^{(1)} x_0 + \Theta_{21}^{(1)} x_1 + \Theta_{22}^{(1)} x_2 + \Theta_{23}^{(1)} x_3)$

$z_2^{(2)}$

$a_3^{(2)} = g(\Theta_{30}^{(1)} x_0 + \Theta_{31}^{(1)} x_1 + \Theta_{32}^{(1)} x_2 + \Theta_{33}^{(1)} x_3)$ → $z_3^{(2)}$

Activation function

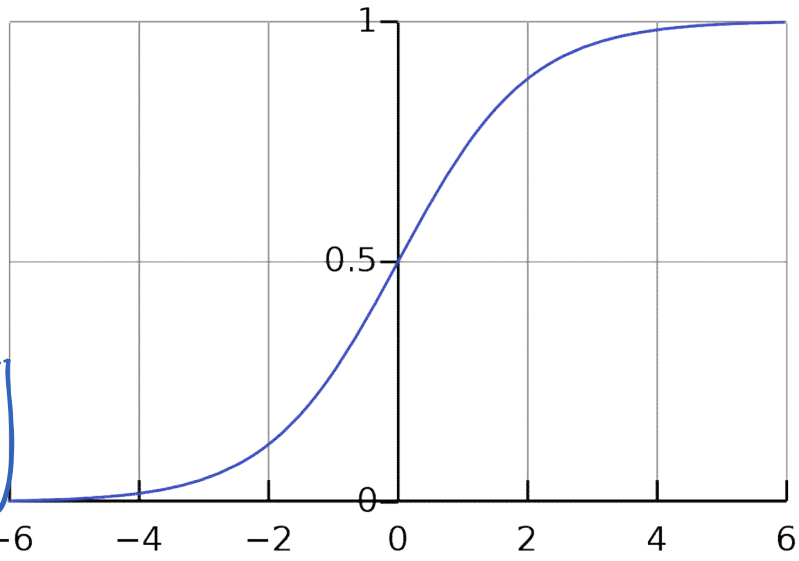
$a^{(l)} = g(W^{(l)} a^{(l-1)} + b^{(l)})$

$\Theta^T a^{(l-1)} \rightarrow \begin{bmatrix} 1 \rightarrow a_0^{(l-1)} \\ \vdots \end{bmatrix}$

Logistic, sigmoid

Function:

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$



Derivative:

$\sigma'(x) = \sigma(x)(1 - \sigma(x))$

$f(x)\big(1 - f(x)\big)$

range:

[0 , 1)

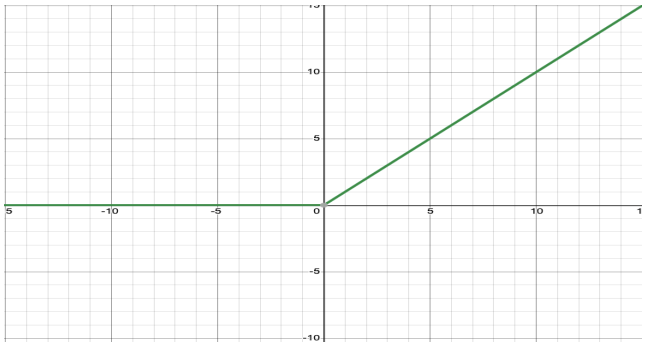
Activation function

ReLU

Function:

$$\begin{cases} 0 & \text{if } x \leq 0 \\ x & \text{if } x > 0 \end{cases}$$

$$= \quad \max\{0, x\} = x\mathbf{1}_{x>0}$$



$z = \theta^T x$

$a = g(z)$

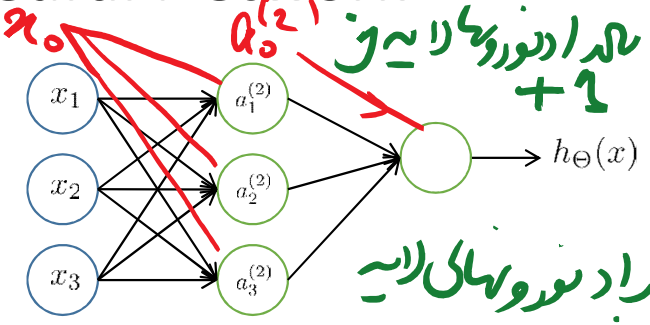
Derivative:

$$\begin{cases} 0 & \text{if } x < 0 \\ 1 & \text{if } x > 0 \\ \text{undefined} & \text{if } x = 0 \end{cases}$$

range:

$(0\ ,\ \infty)$

Neural Network



$a_i^{(j)}$ = "activation" of unit i in layer j

$\Theta^{(j)}$ = matrix of weights controlling function mapping from layer j to layer $j+1$

$$
\begin{cases}
a_1^{(2)} = g(\Theta_{10}^{(1)} x_0 + \Theta_{11}^{(1)} x_1 + \Theta_{12}^{(1)} x_2 + \Theta_{13}^{(1)} x_3) \\
a_2^{(2)} = g(\Theta_{20}^{(1)} x_0 + \Theta_{21}^{(1)} x_1 + \Theta_{22}^{(1)} x_2 + \Theta_{23}^{(1)} x_3) \\
a_3^{(2)} = g(\Theta_{30}^{(1)} x_0 + \Theta_{31}^{(1)} x_1 + \Theta_{32}^{(1)} x_2 + \Theta_{33}^{(1)} x_3)
\end{cases}
$$

$$
h_\Theta(x) = a_1^{(3)} = g(\Theta_{10}^{(2)} a_0^{(2)} + \Theta_{11}^{(2)} a_1^{(2)} + \Theta_{12}^{(2)} a_2^{(2)} + \Theta_{13}^{(2)} a_3^{(2)})
$$

If network has s_j units in layer j, s_{j+1} units in layer $j+1$, then $\Theta^{(j)}$ will be of dimension $s_{j+1} \times (s_j + 1)$